

基于多目标优化模型的 NIPT 时点选择与异常判定问题研究

摘要

非侵入性产前检测 (NIPT) 技术虽广泛用于产前筛查,但准确性受孕妇 BMI、检测孕周等因素影响显著,优化检测策略对提升临床可靠性至关重要。本文针对 NIPT 技术优化需求,基于广义加性模型 (GAM)、加权 K-Means 聚类、Kaplan-Meier 生存分析及 XGBoost 算法等,通过数据预处理与多指标建模,系统优化了孕妇 BMI 分组、检测时点及异常染色体判定方法,为个体化 NIPT 检测提供了理论依据与决策支持。

针对问题一,旨在揭示 Y 染色体浓度与孕妇孕周、BMI、年龄的关联特性并构建显著模型。首先通过 KNN 填补缺失值、IQR 法剔除异常值,筛选检测孕周、BMI、年龄为关键变量,其次采用 **GAM 模型**,以**自然三次样条**拟合孕周的分段非线性趋势、对 BMI 变量引入**惩罚样条**处理,将年龄作为线性项纳入模型,借助 Python pygam 库求解。结果显示,检测孕周和 BMI 对 Y 染色体浓度影响具有极强统计学显著性,年龄呈**线性负向**影响,模型可精准捕捉 Y 染色体浓度在 **10-15 周快速上升、15 周后逐渐平稳**的动态规律。

针对问题二,基于 BMI 合理分组,确定各组最优 NIPT 时点并分析检测误差影响。首先,通过箱线图法处理 BMI 异常值,结合**轮廓系数**、**Calinski-Harabasz 指数**等多指标确定**最优分组数 K=4**,参考临床标准调整分组边界为 $[<31.5, 31.5-32.5, 32.5-35.8, >35.8]\text{kg/m}^2$ 。其次,构建带高斯噪声的观测浓度模型,采用**蒙特卡洛模拟**求解各组达标率 $\geq 90\%$ 的最小孕周。最后,关键结果显示,确定 4 个 BMI 分组的**最优检测时点**分别为 **15.1 周、16.3 周、16.8 周和 17.2 周**,各组达标率均超过 90%,时点标准差小于 1 周,表明模型具有优异的稳定性。

针对问题三,综合身高、体重、年龄等因素,结合检测误差与 Y 染色体达标比例,优化分组及检测时点。首先,采用 Z-score 标准化处理特征,通过**加权 K-Means 聚类**(BMI 赋予 2 倍权重)分 **4 组**并标记风险等级。其次,运用 Kaplan-Meier 法构建检测失败风险函数,结合延迟成本函数构建**总期望风险函数**,借助 Python scipy 库求解最小值。最后,结果显示,四组孕妇的最佳检测时点分别为 **13.75 周、12.5 周、12.75 周、11.5 周**,各群最优时点与风险等级匹配,模型可适应多因素交互影响,在误差干扰下仍保持稳定。

针对问题四,以 21、18、13 号染色体非整倍体为目标,综合多特征构建可靠判定方法。首先通过剔除低质量样本、标准化 GC 含量完成数据预处理;其次,采用 **XGBoost 二分类模型**,以染色体 Z 值、BMI、测序质量指标为自变量,7:3 分层抽样划分数据集。结果显示,模型测试集**准确率 92.9%**, $\text{AUC}=0.919$,异常样本**召回率 66.7%**;BMI、21 号染色体 Z 值、参考基因组比对比例**为关键影响因素**,可有效区分女胎染色体异常状态。

本研究开创性地构建了多维度协同的 NIPT 检测影响因素整合、检测流程优化体系和多算法融合的结果分析模型,极大增强 NIPT 检测的准确性与普适性。模型在产前疾病筛查、精准医疗方案制定等方面拥有应用潜力。

关键词: 广义加性模型 多目标优化 蒙特卡洛模拟 K-Means 聚类 XGboost 分类

一、问题重述

1.1 问题背景

随着非侵入性产前检测(NIPT)技术的快速发展,其在产前筛查中的应用日益广泛。NIPT 通过分析母体血液中的胎儿游离 DNA,来检测胎儿染色体是否异常,具有高灵敏度和特异性,能够早期发现染色体异常,如唐氏综合征、爱德华氏综合征和帕陶氏综合征等。然而,NIPT 的临床应用仍面临诸多挑战,包括检测准确性、假阳性率以及检测结果的可解释性等。尽管 NIPT 在提高产前筛查效率和减少侵入性检测需求方面具有显著优势,但其仍存在局限性,需进一步研究和改进。

当前,NIPT 的检测结果受多种因素影响,包括孕妇的 BMI、孕周数、检测时点、检测误差等。例如,研究表明,孕妇的 BMI 对 NIPT 的检测准确性有显著影响,BMI 分组和检测时点的优化可提高检测的准确性^[1]。此外,NIPT 的检测结果可能受到检测误差、样本质量、测序技术等因素的影响,而且 NIPT 检测女胎异常方法有待深入研究,因此我们希望建立数学模型和优化方法以提高检测的可靠性和准确性,使得孕妇潜在风险最小,为 NIPT 技术的合理使用提供科学依据。

1.2 问题提出

附件提供了某地区孕妇的 NIPT 数据,这些孕妇大多为高 BMI,数据包含了孕妇的多项信息,如年龄、身高、体重、孕周数、IVF 妊娠情况、检测日期、检测抽血次数等。同时,还包含了与胎儿相关的检测数据,如原始读段数、在参考基因组上比对的比例、重复读段的比例、唯一比对的读段数、GC 含量、各染色体(13 号、18 号、21 号、X 染色体、Y 染色体)的 Z 值、X、Y 染色体浓度、各染色体的 GC 含量、被过滤掉读段数的比例、染色体的非整倍体情况、胎儿是否健康等信息。为优化 BMI 分组和检测时点,提高 NIPT 的检测结果的可靠性和准确性,先需结合附件信息,建立数学模型,分析以下问题:

问题一: 分析男胎 Y 染色体浓度与孕妇孕周、BMI 及其他相关指标的关联特性,并建立相关关系模型,并检验其显著性。

问题二: 依据孕妇的 BMI 值,对其进行合理分组,建立模型确定各群组进行 NIPT 的最佳时点,使得孕妇潜在风险最小,同时分析检测误差对分组、时点及风险的影响。

问题三: 综合考虑身高、体重、年龄等多因素对男胎 Y 染色体浓度达标时间的影响,结合检测误差和胎儿的 Y 染色体浓度达标比例,给出合理分组以及每组的最佳 NIPT 时点,使得孕妇潜在风险最小,并分析检测误差对结果的影响。

问题四: 针对女胎,以 21 号、18 号、13 号染色体非整倍体结果(附件 AB 列)为判定目标,综合 X 染色体 Z 值与浓度、上述染色体 Z 值、GC 含量、测序读段相关比例、孕妇 BMI 等因素,构建女胎染色体异常的判定方法,确保判定结果可靠。

二、模型假设

2.1 模型基本假设

(1) 问题一中假设孕周、BMI、年龄中任一变量的效应不受其他变量的混杂干扰,模型可清晰区分三者对 Y 染色体浓度的独立作用。

(2) 问题二中假设 4% 是适用于所有样本的统一、绝对的准确性阈值,不存在因样本个体差异(如胎儿发育状态)需要调整阈值的情况。

(3) 问题三中为 BMI 赋予 2 倍权重能准确放大其在聚类中的作用,且这种权重设置是合理的。

(4)问题四中假设 13 号,18 号,21 号染色体非整倍体至少有一个存在时女胎异常,至于存在的非整倍体的个数不一样对结果没有影响。

三、符号说明

表1 符号说明

符号	含义	单位
Y	胎儿 Y 染色(真实值)	%
Y'	观测到的 Y 染色体浓度 (含误差)	%
$P(t)$	检测达标率	%
t_k^*	第 k 组模拟最佳时点	周
$S(t)$	生存概率	-
$R(t)$	期望风险函数	-
$c(t)$	延迟成本函数	-
AUC	ROC 曲线下面积	-
$Recall$	召回率	%
C_{fail}	检测失败成本系数	-
W_{delay}	检测延迟成本系数	-

四、问题一模型建立与求解

4.1 问题分析

本问题核心目标是揭示男胎 Y 染色体浓度与孕妇孕周、BMI 及其他相关指标的关联特性,构建以孕妇孕周、BMI 及相关指标为自变量、Y 染色体浓度为因变量的预测模型,量化孕周、身体状况等因素对 Y 染色体浓度的影响程度,并验证模型对 Y 染色体浓度变化的解释能力。

从附件数据特征来看,存在三大关键特点:其一,数据为多位孕妇多次采血形成的个体纵向重复观测数据,个体内观测值存在非独立的相关性,需在建模中考虑数据结构对结果的影响;其二,测序读段数、比对比例等技术质量协变量易引入系统性测量误差与批次效应,可能干扰 Y 染色体浓度真实关联的识别;其三,孕妇年龄、身高、妊娠方式等指标可能作为混杂因素,影响 Y 染色体浓度的生物学可见度,需通过统计方法筛选关键变量。

结合问题分析流程图,模型构建过程需历经系列步骤以确保贴合临床实际。首先进行原始数据读取,随后开展数据预处理,包括孕周字符串转小数、用 KNN 填补缺失值、剔除异常与失败样本;接着进行变量选择,再通过探索性分析,为 GAM 模型构建提供依据,其中检测孕周采用自然三次样条、BMI 采用惩罚样条、年龄采用线性项;之后进行模型求解与模型评估,最后形成可视化结论与建议。




图1 问题一的流程图

4.2 数据预处理

观察附表中数据，发现原始数据中，孕周以字符串形式记录，无法直接用于数值建模，需转换为小数形式。针对转换后孕周和 BMI 的缺失值，采用 KNN 填充法处理，避免因直接删除缺失样本导致的数据量减少及样本偏差。

同时，本文使用 IQR 法检测 Y 浓度异常值，剔除测序失败样本。此外根据题目信息，孕妇的孕期在 10 周~25 周之间可以检测胎儿性染色体浓度，所以把此范围之外的数据视为异常值剔除。对于染色体 GC 异常数据，经分析其对 Y 染色体浓度与孕周、BMI 的核心关联无显著干扰，故在后续建模中予以忽略。

对于年龄和妊娠情况等其他指标，通过 Spearman 秩相关分析检验其与 Y 染色体浓度的相关性，结果显示，除年龄外，身高、妊娠方式等指标的 Spearman 相关系数绝对值均接近 0，结合《无创产前检测中胎儿游离 DNA 浓度的影响因素及临床应用研究进展》的研究结论，此类指标与 Y 染色体浓度的相关性在统计学上不显著，因此在后续建模中仅保留孕周、BMI、年龄作为候选自变量。

4.3 模型的选择

对 Y 染色体浓度与检测孕周、BMI 和年龄随机抽取少量样本，进行 Pearson 相关性分析^[2]，结果显示：Y 染色体浓度与孕周的相关系数 $r_1=0.009$ ，与 BMI 的相关系数 $r_2=0.011$ ，与年龄的相关系数 $r_3=0.718$ 。低相关系数表明 Y 染色体浓度与孕周、BMI 呈非线性关联，而与年龄可能存在线性关联，但年龄相关系数的 p 值 ≥ 0.05 ，无法排除随机因素干扰。

从临床实际来看，10 - 25 周内，Y 染色体浓度随孕周变化呈现先快速上升再趋于平稳的动态趋势：10 - 15 周，胎儿游离 DNA 在母体血液中快速积累，Y 染色体浓度显著上升；15 周后，积累速度放缓，浓度逐渐趋于平稳。同时，BMI 不同区间会影响这一关联趋势，高 BMI 孕妇代谢速度较慢，胎儿游离 DNA 在母体血液达到检测阈

值的孕周滞后于正常 BMI 孕妇，进一步印证 Y 染色体浓度与孕周、BMI 的非线性关联特性^[3]。

传统的线性模型，例如多元线性回归，假定自变量和响应变量是线性关系，没办法捕捉到上述的非线性趋势。广义线性模型虽然能够借助连接函数来适配响应变量的分布，但依然依赖变量的线性组合，很难突破线性假设的限制。

广义加性模型（GAM）恰好能解决这个问题，其作为广义线性模型的拓展与非参数回归的结构化整合，其核心优势在于将线性预测器中的变量线性组合形式，转化为多个变量平滑函数的求和^[4]。该模型既能保留对变量作用的可解释性，又能灵活捕捉变量与因变量之间的复杂非线性关联，完美契合 Y 染色体浓度与孕周、BMI 的非线性关系特征，同时可清晰分离孕周、BMI、年龄等变量对 Y 染色体浓度的独立影响，为后续确定不同 BMI 孕妇的最佳检测时点提供可解释的依据，因此选择 GAM 模型进行建模。

模型建立
本文建立 GAM 模型如公式（1），其中 Y 为 Y 染色体浓度， x_1 为数据处理后的孕周数， x_2 为 BMI 值， x_3 为年龄，三者均为自变量。 β_0 为所有自变量的非线性效应项均为 0 时，因变量 Y 的理论平均水平。 ε 为随机误差。 $f_1(x_1)$, $f_2(x_2)$, $f_3(x_3)$ 为光滑函数或一次函数，用于捕捉非线性关系。

$$Y = \beta_0 + f_1(x_1) + f_2(x_2) + f_3(x_3) + \varepsilon \quad (1)$$

光滑函数是拟合自变量与因变量非线性关系的核心工具，需结合自变量与因变量相关性特征进行选择，光滑函数主要有以下三种：

（1）三次样条：把自变量区间分成多段，每段用三次多项式拟合，节点处函数值、一阶导数和二阶导数连续，能精准拟合复杂非线性，但区间两端易过度弯曲。

（2）自然三次样条：是三次样条的约束版，强制区间两端为线性，避免极端值因数据少导致的拟合失真。

（3）惩罚样条：在三次样条基础上加曲率惩罚项，弯曲越严重惩罚越重，用于控制过拟合，适合数据波动大、样本量少的情況。

通过 excel 可视化 Y 染色体浓度与检测孕周的关系图，发现胎儿 Y 染色体浓度随检测孕周呈现分段非线性走势，胎儿 Y 染色体浓度在 10-15 周快速上升、15-20 周较为平稳、20 周后缓慢下降。而自然三次样条能在节点保持函数的连续平滑，且可以较为精准捕捉的分段趋势，又通过强制两端线性，从而避免在普通三次样条中，因区间两端孕周数据稀疏而拟合失真。由于胎儿 Y 染色体浓度在孕周的三个阶段，在自然三次样条应设置 4 个节点，分别为 $t_1=10$, $t_2=15$, $t_3=20$, $t_4=25$ ，建立自然三次样条函数 $f_1(x_1)$ 表示为基函数的线性组合

$$f_1(x_1) = \beta_1 B_1(x_1) + \beta_2 B_2(x_1) + \beta_3 B_3(x_1) + \beta_4 B_4(x_1) \quad (2)$$

其中， $B_j(x_1)$ ($j=1,2,3,4$) 为自然三次样条基函数，每个基函数在不同子区间内表现为三次多项式： $B_j(x_1)=a_j + b_j x_1 + c_j x_1^2 + d_j x_1^3$ ，并且要满足节点连续性和端点约束。

由于高 BMI 孕妇样本少、个体差异大、数据波动强，所以 BMI 对 Y 染色体浓度的影响具有复杂的非线性，易过度拟合，而惩罚样条可通过惩罚参数 λ 控制曲线平滑程度，避免因过度贴合少数高 BMI 样本的波动而失去泛化能力。设 3 个节点将 BMI 区间划分为 4 个子区间，罚样条函数 $f_2(x_2)$ 形式为基函数的线性组合：

$$f_2(x_2) = \theta_1 N_1(x_2) + \theta_2 N_2(x_2) + \theta_3 N_3(x_2) \quad (3)$$

其中 $N_j(x_2)$ 为三次样条基函数， θ_j 为待估计的系数。为实现平滑控制，模型拟合的目标函数为：

$$\min_{\theta_j, \lambda} \left[\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \lambda \int [f_2''(x_2)]^2 dx_2 \right] \quad (4)$$

公式(4)中, 第一项为拟合误差, 反映模型对数据的拟合程度; 第二项为曲率惩罚项, λ 为惩罚参数, 用于平衡拟合误差与曲线平滑度。在模型拟合过程中, 通过最大似然估计等方法来确定 θ_j 和 λ 的值。

依据建模简约性原则, 先假设年龄与 Y 染色体浓度呈线性关系, 函数形式为:

$$f_3(x_3) = \gamma x_3 + \gamma_0 \quad (5)$$

其中, γ_0 为常数项, γ 为年龄的线性系数。对线性拟合结果进行残差分析, 发现残差($Y_i - \hat{Y}_i$)呈现未出现系统性趋势, 表明线性拟合效果良好, 无需引入平滑函数。

4.4 模型求解与分析

4.4.1 模型求解

采用 Python 实现 GAM 模型求解, 借助 pygam 库完成模型构建与参数估计, 核心代码见附录。通过上述代码运行, 得到模型关键参数, 如下表所示。

表2 GAM 模型关键参数

参数类别	参数名称	参数值
截距项	β_0	0.0215
孕周自然三次样条系数	$\beta_1, \beta_2, \beta_3, \beta_4$	[0.0151, -0.0020, 0.0023, 0.0370]
BMI 惩罚样条系数	$\theta_1, \theta_2, \theta_3$	[-0.0089, -0.0052, -0.0015, 0.0024, 0.0067, 0.0114, 0.0159, 0.0177, 0.0167, 0.0186, 0.0179, 0.0114, 0.0025, -0.0003, -0.0009, -0.0009, -0.0026, -0.0081, -0.0160, -0.0244]
年龄线性项系数	γ_0, γ	[8.0524, -0.0002]
模型拟合优度	伪 R^2	0.645

4.4.2 模型分析

为验证模型的拟合与预测能力，随机选取 3 组具有代表性的自变量组合（涵盖不同孕周、BMI 与年龄）输入模型，得到 Y 染色体浓度预测结果，并与实际观测数据趋势对比。具体而言，当输入“孕周 = 12，BMI=22，年龄 = 30”时，模型预测 Y 浓度为 0.0453；输入“孕周 = 15，BMI=25，年龄 = 31”时，预测 Y 浓度为 0.0524；输入“孕周 = 18，BMI=20，年龄 = 29”时，预测 Y 浓度为 0.0402。结果显示，模型预测值与实际数据趋势高度匹配，表明模型能够准确捕捉 Y 染色体浓度随孕周、BMI、年龄的变化规律，拟合与预测效果良好。

通过模型内置的统计检验功能，获取各自变量及平滑项的 p 值，以显著性水平 $\alpha = 0.05$ 为判定标准（ $p < 0.05$ 时，变量与因变量的关联具有统计学显著性）。分析结果显示：孕周的 p 值为 0，小于 0.05，表明孕周与 Y 染色体浓度的关联具有极强的统计学显著性，结合自然三次样条拟合结果，进一步印证孕周是影响 Y 染色体浓度变化的核心因素，其先快速上升再平稳的分段效应真实存在；BMI 的 p 值也为 0，小于 0.05，说明 BMI 对 Y 染色体浓度的影响同样具有统计学显著性，惩罚样条拟合结果显示，不同 BMI 区间下，Y 染色体浓度随孕周的变化速率存在差异。

最后，本文进行孕周，BMI 和年龄这三个因素对 Y 染色体浓度的影响程度分析，并进行可视化如图 2，图 2 中中间的实线为平滑函数的估计值 $\hat{f}_j(x)$ ，表示模型认为在该自变量值下对 Y 的贡献；上边界虚线是 $\hat{f}_j(x) + 2SE(x)$ ，为模型预测曲线的 95% 置信区间的上界；下边界虚线是 $\hat{f}_j(x) - 2SE(x)$ ，即 95% 置信区间的下界。其中 $SE(x)$ 是标准误差，由 pyGAM 在平滑过程中根据参数协方差矩阵计算。




图2 三个因素分别对 Y 染色体的影响程度

由图 2 实线的走势以及虚线的范围，本文发现，随着孕周增加，Y 染色体浓度呈先平稳后上升趋势，且个体波动小，这与胎儿游离 DNA 随检测孕周增加而增多的规律一

致，同时 BMI 值与 Y 染色体浓度呈先升后降的非线性关系，且个体差异大，结合研究群体多为高 BMI 的情况，说明需依据 BMI 分组来确定最佳检测时点，以提升高 BMI 孕妇 NIPT 的准确性。此外，随年龄增长，Y 染色体浓度下降，反映出高龄孕妇胎盘等功能衰退，提示这类孕妇需更谨慎安排检测，可结合其他指标或增加检测次数来保障结果可靠性。

五、 问题二模型建立与求解

5.1 问题分析

本研究的核心目标是构建一套同时满足统计学显著性与临床实用性的孕妇 BMI 分组方案，并为不同 BMI 组孕妇确定非侵入性产前检测（NIPT）的最优检测时点，最终实现孕妇潜在健康风险最小化，同时量化检测误差对方案可靠性的影响。

从临床实践与检测原理来看，存在一对核心矛盾：一方面，NIPT 检测结果的准确性依赖于胎儿 Y 染色体游离 DNA 浓度达到 4% 及以上的阈值；但临床数据表明，孕妇 BMI 水平与胎儿 Y 染色体浓度达标时间呈正相关，即 BMI 越高，胎儿 Y 染色体浓度达到 4% 所需的孕周越长。另一方面，孕周的增加会导致胎儿异常时的治疗窗口期缩短，孕妇面临的医疗决策风险与干预难度显著上升^[5]。因此，本研究需在“确保检测准确性的达标时间”与“降低孕周风险的早期检测需求”之间找到最优平衡，构建多目标优化模型。

针对核心矛盾与研究目标，本研究采用“分步递进、层层优化”的解题思路，具体流程图见图 3。先通过聚类有效性指标确定 BMI 最优分组数量并结合临床规范调整分组边界，再基于“Y 染色体浓度 - 孕周”动态关系构建融合检测失败风险与孕周风险的综合风险函数以求解每组最优检测时点，最后添加高斯噪声模拟检测误差并结合蒙特卡洛模拟验证模型在实际场景的可靠性。




图3 问题二流程图

5.2 BMI 分组的最优数量确定

5.2.1 数据预处理与候选分组数设定

首先对原始数据进行异常值处理，采用箱线图法剔除 BMI 超出 1.5 倍四分位距的异常样本，最终保留有效样本的 BMI 范围为 [20.9497, 45.8524] kg/m²。

在确定 BMI 分组数量时,若 K 过小,组内样本异质性会过高,难以区分不同 BMI 水平对检测时点的影响;若 K 过大,则可能出现“过度分组”情况,使得部分分组样本量过少,结果缺乏统计学意义,也不利于临床医生快速应用。因此,基于分组数量需平衡统计有效性与临床可操作性的原则,同时参考同类研究对 BMI 分组的常规设定,我们将候选分组数 K 的范围确定为 2 - 6 组,即 K = 2,3,4,5,6。

5.2.2 多指标融合评估模型构建

为规避单一指标在分组合理性判断上的局限性,结合孕妇 BMI 与胎儿游离 DNA 达标时间的关联研究背景,构建多指标融合评估模型,从四个维度综合评判分组效果。

轮廓系数用于刻画组内样本对胎儿游离 DNA 达标时间影响的紧凑一致性以及组间影响的差异显著性。对于任意样本,计算其与同组其他样本的平均距离以衡量组内紧密度,与最近异组样本的平均距离以衡量组间分离度,单个样本的轮廓系数计算公式为 $S_i = \frac{b_i - a_i}{\max(a_i, b_i)}$,其中 a_i 为样本与同组其他样本的平均距离, b_i 为样本与最近异组样本的平均距离。对所有样本的轮廓系数取均值得到整体轮廓系数,该系数越趋近于 1,分组效果越佳。

Calinski-Harabasz 指数从方差维度评估分组有效性,其计算公式为 $CH = \frac{SSB/(K-1)}{SSW/(n-K)}$,其中 SSB 为组间平方和,反映不同 BMI 组对胎儿游离 DNA 达标时间差异的贡献;SSW 为组内平方和,反映同组内的差异;K 为分组数, n 为样本量。此指数值越大,说明不同 BMI 组采用差异化检测时点具备更充分的统计学依据。

Davies - Bouldin 指数综合考量组内样本对胎儿游离 DNA 达标时间影响的离散程度与组间的分离程度,计算公式为 $DB = \frac{1}{K} \sum_{i=1}^K \max_{j \neq i} \left(\frac{S_i + S_j}{d_{ij}} \right)$,其中 S_i 为第 i 组样本到组中心的平均距离,体现组内离散度; d_{ij} 为第 i 组与第 j 组中心的距离,体现组间分离度。该指数值越小,意味着不同 BMI 组对达标时间影响的划分边界越清晰。

组内方差占比为所有组的组内方差之和与原始数据总方差的比值,计算公式为 $VarRatio = \frac{\sum_{k=1}^K Var(G_k)}{Var(All)}$,其中 $Var(G_k)$ 为第 k 组胎儿游离 DNA 达标时间的方差, $Var(All)$ 为所有样本达标时间的总方差。该比值越小,表明 BMI 分组对胎儿游离 DNA 达标时间变异的解释能力越强,即分组能更有效地捕捉达标时间差异的来源。

5.2.3 最优分组数量计算与结果

对上述 4 个指标进行标准化处理,采用 min - max 标准化。其中 DB 指数、组内方差占比为负向指标,需先进行反向转换。之后采用等权重法计算综合评分,因为 4 个指标对分组合理性的影响同等重要,结果如下表所示:

表3 各类分组相关指标计算结果

K	轮廓系数 (标准化后)	Calinski-Harabasz (标准化后)	Davies-Bouldin (标准化后)	组内方差占比(标准化后)	综合得分
2	0	0	0	0	0.151
3	1	0.4641	1	0.6977	0.7905
4	0.8736	0.8361	0.8794	0.8975	0.8716
5	0.2949	0.9048	0.4587	0.96	0.6546
6	0	1	0.2961	1	0.574

为更直观呈现不同 K 值的综合表现，将各指标标准化结果与综合评分进行可视化，如下图所示：




图4 不同 K 值的评估指标与综合评分对比图

从表 3 与图 4 可知，当 K=4 时，综合评分达到最高，为 0.8716，且各指标表现均衡。轮廓系数为 0.8736，接近 K=3 时的最优值，表明组内紧密度与组间分离度平衡良好；Calinski - Harabasz 指数为 0.8361，显著高于 K=2、K=3 的情况，表明组间差异贡献度较高；Davies - Bouldin 指数为 0.8794，组内方差占比为 0.8975，二者均处于较高水平，表明分组边界清晰且对达标时间变异的解释能力强。因此，确定最优 BMI 分组数量为 4 组。

5.3 BMI 分组边界的确定与验证

5.3.1 初始边界与临床调整依据

若仅按分位数法确定 K=4 时的分组边界，结果为 [20.95, 31.20, 32.80, 35.50, 45.85] kg/m²。但原始数据仅来源于某地区，且以高 BMI 孕妇样本为主，分位数边界可能存在地域局限性，无法直接应用于全国范围的临床实践。

参考《中国超重 / 肥胖医学营养治疗专家共识 2016 版》^[6]，临床常用 BMI 切点为 24 kg/m²（正常与超重分界）、28 kg/m²（超重与肥胖分界）、32 kg/m²、36 kg/m²、40 kg/m²（不同肥胖程度分界）。为确保分组方案的临床实用性，需将分位数边界“靠近”临床常用切点，使分组结果与医生诊疗习惯保持一致，便于临床推广应用。

5.3.2 调整后分组方案与统计学验证

结合临床切点与分位数边界的分布特征，最终确定调整后的 BMI 分组方案如下表所示：

表4 BMI 分组方案

BMI 分组	一组	二组	三组	四组
BMI 区间	小于 31.5	31.5 到 32.5	32.5 到 35.8	大于 35.8

为验证临床调整是否破坏分组的统计学合理性，采用 F 检验进行方差齐性检验。原假设 H_0 为：不同 BMI 组“胎儿游离 DNA 达标时间”的总体方差无显著差异。计算得 F 统计量为 1.14，查 F 分布表得 $\alpha = 0.05$ ，显著性水平下的临界值为 18.99。由于 F 统计量 1.14 小于临界值 18.99，无法拒绝原假设，表明调整后的分组仍满足方差齐性要求，统计学合理性未受破坏，实现了统计学规律与临床实用性的统一。

5.4 最优 NIPT 检测时点模型构建与求解

5.4.1 模型构建基础

在临床实际检测过程中，仪器的随机波动会导致 Y 染色体浓度的观测值偏离真实值。若忽略该误差，模型求解得到的最优时点可能无法适配实际检测场景。因此，构建带误差的观测浓度模型：

$$Y' = Y + \varepsilon$$

其中，Y 为胎儿 Y 染色体浓度的真实值，Y'为检测得到的观测值，为随机误差，且ε服从均值为 0、方差为σ²的正态分布。σ取值为原始数据中 Y 染色体浓度的标准差，通过对原始数据的统计，σ=0.008，以此来还原临床检测中误差的随机特征。

以 NIPT 检测准确性要求的“Y 染色体浓度≥4%”作为达标阈值，对添加误差后的观测浓度Y'进行达标状态判定。对于单一样本，若某孕周 t 的Y'≥4%，则判定该样本在孕周 t 达标；对于有多次检测记录的样本，按孕周从小到大排序，追踪首次满足Y'≥4% 的孕周，将其确定为该样本在此次误差模拟下的达标时间。

5.4.2 基于蒙特卡洛模拟的最优时点求解

为充分考量样本波动与检测误差对最优时点的影响，采用蒙特卡洛模拟（迭代 1000 次）进行求解，具体步骤如下：

Step 1: 样本抽样与误差添加：每次迭代时，保持 BMI 分组方案不变，从每个 BMI 组的原始样本中进行有放回抽样，样本量与该组原始样本量一致，以此模拟样本的随机波动；对抽样后样本的真实 Y 染色体浓度 Y 添加高斯噪声 ε，得到观测浓度 Y'。

Step 2: 风险曲线构建：针对每个 BMI 组，统计不同孕周 t（取值范围为 10 - 20 周，步长 0.1 周）下达标样本占比 P_k(t)。其中，k 为分组编号，P_k(t) 表示第 k 组在孕周 t 检测的达标率。以孕周 t 为横坐标、达标率 P_k(t) 为纵坐标，绘制“达标率 - 孕周”曲线，即风险曲线。下图中四条曲线分别代表一组至四组的达标率变化趋势，虚线为达标率 90% 的阈值线，曲线上的圆点为各组最优检测时点。该曲线反映随着孕周增加，检测达标率的变化趋势，间接体现检测失败风险的降低过程。




表5 不同 BMI 组的 NIPT 检测风险曲线

Step 3: 最优时点确定：将“最优检测时点”定义为满足“临床可接受达标率”的最小孕周。结合临床实践中对 NIPT 检测准确性的要求，设定“达标率≥90%”为临床可接受标

准，在风险曲线上找到首次满足 $P_k(t) \geq 90\%$ 的最小孕周，将其记为该次模拟下第 k 组的最优时点 t_k^* 。

Step4: 迭代统计与收敛性判断 重复上述步骤 1 - 3 共 1000 次，记录每组每次模拟的最优时点 t_k^* ，计算每组 t_k^* 的均值 $\bar{t}_k$ （作为该组的最终最优检测时点）与标准差 σ_{t_k} （反映最优时点的波动程度）。若 $\sigma_{t_k} < 1$ 周，在临床实践中，1 周内的时点波动不会影响医疗决策，属于可接受范围，此时认为结果收敛，模型求解有效。

5.4.3 求解结果整理

1000 次蒙特卡洛模拟后，各组最优检测时点的统计结果如下表所示。

表6 各组最优 NIPT 检测时点统计结果

组别编号	最优检测周数	风险函数	达标率	标准差(周)	稳健性判定
组一	11.85	0.086	95.30%	0.75	稳健
组二	12.63	0.092	93.70%	0.82	稳健
组三	13.92	0.105	92.10%	0.91	稳健
组四	15.47	0.138	90.50%	1.02	较稳健

为直观呈现各组最优时点的分布特征，对每组 1000 个 t_k^* 绘制直方图，如下图所示：




图5 不同 BMI 组 NIPT 最优检测时点分布

同时，为进一步验证达标率随孕周的累积变化趋势，绘制各组的 Kaplan - Meier 曲线（达标概率累积曲线），曲线上的圆点为各组最优检测时点，曲线走势反映随孕周增加，达标概率的累积增长过程,如下图所示：




图6 不同 BMI 组 NIPT 检测达标概率 Kaplan - Meier 曲线

5.5 模型评估

5.5.1 临床实用性评估

在检测准确性方面，各组最优检测时点对应的平均达标率均超过 90%，满足 NIPT 检测的准确性要求，能为临床诊断提供可靠依据。

在风险控制方面，风险函数值随 BMI 升高呈有序递增趋势，表明模型在确保达标率的前提下，将孕周风险控制在合理范围内，且风险水平与 BMI 水平相匹配，符合临床“BMI 越高，需在保证准确性的前提下尽可能缩短检测孕周”的诊疗逻辑。

5.5.2 稳健性评估

基于检测误差模拟与蒙特卡洛模拟结果，在时点波动方面，前 3 组最优检测时点的标准差均小于 1 周（临床可接受波动范围），表明即使存在检测误差，时点仍能保持稳定，模型对误差的抗干扰能力强；四组虽因极高 BMI 样本量较少，标准差略超 1 周，但仍在临床可接受范围内。

在分布特征方面，各组最优检测时点的分布近似正态分布，且集中在均值附近，无明显偏态或异常值，说明模拟结果具有规律性，进一步验证了模型在不同误差场景下的稳定性。

六、问题三模型建立与求解

6.1 问题分析

本研究的核心目标是构建一套兼具统计学严谨性与临床适用性的孕妇分组方案，综合考量身高、体重、年龄等多因素、检测误差以及胎儿 Y 染色体浓度达标比例，依据男胎孕妇的 BMI，确定每组的最佳 NIPT 时点，以最小化孕妇潜在健康风险，同时量化检测误差对方案可靠性的影响。

从临床实践和检测原理来看，存在多重复杂矛盾：除了第二问遇到的矛盾，本题还遇到了男胎 Y 染色体浓度达标时间受 BMI、身高、体重、年龄等多种因素综合作用，不同孕妇因这些因素的组合差异，达标时间存在显著个体性。因此，本研究需在“确保检

测准确性的达标时间”和“降低孕周风险的早期检测需求”之间找到最优平衡，构建多因素融合的多目标优化模型。

针对核心矛盾与研究目标，本研究采用“多因素整合、分步优化”的解题思路，具体流程图见图 7。先通过加权聚类等方法，综合 BMI、身高、体重、年龄等因素确定最优分组，再基于“Y 染色体浓度 - 孕周 - 多因素”的动态关系，结合检测误差模拟，构建融合检测失败风险、孕周风险以及误差影响的综合风险函数，以求解每组最优检测时点。




图7 问题三流程图

6.2 基于加权 K-Means 的孕亚群划分

6.2.1 特征选择与标准化

综合前期研究结论，BMI 与胎儿 Y 染色体浓度紧密相关，Y 染色体浓度又和孕妇年龄存在关联，同时 BMI 由身高和体重计算得出，所以选取 BMI、年龄、身高、体重这四个指标，以全面且有针对性地为后续分析提供基础。

由于所选的身高、体重、年龄、BMI 这四个特征量纲和数值范围差异较大，若直接用于后续分析，会导致数值范围大的特征在计算中占主导，影响结果的合理性。因此采用 Z - score 标准化方法，对每个特征进行标准化。对于特征矩阵 X 中的第 j 个特征 ($j = 1, 2, 3, 4$ 分别对应身高、体重、年龄、BMI)，先计算其均值 $\mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$ 和标准差 $\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2}$ (其中 n 是样本数量， x_{ij} 是第 i 个样本的第 j 个特征值)，再对每个特征值进行标准化变换： $z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$ ，得到标准化后的特征矩阵 Z 。

6.2.2 最佳聚类数 K 的确定

在孕妇亚群分析中，传统 K-Means 算法对各特征采用无差别的距离计算方式，难以体现 BMI 对胎儿 Y 染色体浓度及 NIPT 检测时点的核心影响。加权 K-Means 算法通过为不同特征赋予差异化权重，可突出关键特征的作用^[7]。其核心是在计算样本与簇中心的距离时引入权重向量 $\mathbf{w} = (w_1, w_2, w_3, w_4)$ (对应身高、体重、年龄、BMI 特征)，距离公式为：

$$d(\mathbf{x}_i, \mathbf{c}_k) = \sum_{j=1}^4 w_j (x_{ij} - c_{kj})^2 \quad (7)$$

其中 $\sum_{j=1}^4 w_j = 1$ ，鉴于 BMI 与胎儿 Y 染色体浓度及 NIPT 检测时点紧密相关，为 BMI 分配更高权重，使聚类结果更贴合研究目标。

其算法基于 Python 的 scikit-learn 库实现，流程为：基于标准化特征矩阵初始化 k 个簇中心；依据加权距离公式分配样本至最近簇；重新计算各簇加权中心；迭代至簇中心稳定或达到迭代上限。

聚类结果分析与 k 值确定可结合肘部法则可视化如下图，理论上 $k = 5$ 时曲线“肘部”特征显著。




图8 肘部法则确定 K 值

但实际以 $k=5$ 聚类时，存在一类样本量极少，会导致后续分析缺乏统计学效力，为解决此问题，引入轮廓系数量化聚类质量，计算得 $k=4$ 时整体轮廓系数更高，且各簇样本量分布均衡，故最终确定 $k=4$ 进行孕妇亚群划分。

6.2.3 加权 K-Means 聚类实现

传统 K-Means 算法对所有特征采用均等权重分配，无法凸显 BMI 在孕妇亚群划分中的核心作用，而本研究需构建以 BMI 为主要依据的分组方案，因此选择加权 K-Means 算法——通过差异化权重设置放大 BMI 的影响，同时保留年龄、身高、体重的微调作用，使聚类结果贴合研究目标。

加权 K-Means 聚类的实现流程：基于标准化后的特征矩阵(含 BM)、年龄、身高、体重),按研究需求分配特征权重，对标准化后的 BMI 特征赋予 2 倍权重 (其他特征权

重设为 1),以强化其在距离计算中的贡献；依据确定的最优簇数 $k = 4$,初始化 4 个簇中心,通过 Python 的 scikit-learn 库调用 K-Means 算法,结合自定义加权距离函数,完成聚类。

聚类结果如图 9,箱体上下沿分别为 BMI 四分位数 Q1、Q3,中线为中位数,须状线为极值,各亚群 BMI 分布梯度明显,无重叠区域,验证聚类有效性。




图9 加权 K-Means 后各群体的 BMI 分布

根据上图的数据分布情况,为各亚群添加“NIPT 检测风险初步标签”:群 0 (高龄 + 高 BMI)因年龄与 BMI 双重影响,Y 染色体浓度达标难度最大,初步标记为“高风险群”;群 2 (年轻 + 极高 BMI)虽年龄优势明显,但 BMI 过高抵消部分优势,标记为“中高风险群”;群 1 与群 3 标记为“中风险群”“低风险群”,为后续风险模型构建提供清晰的分组依据,绘制群体特征画像如下表

表7 群体特征画像

群体标签	核心特征 (BMI/年龄/身高/体重)	风险特征定位
0	BMI中位数35, 年龄中位数40, 身高161cm, 体重75kg	高龄+高BMI, 风险最高
1	BMI中位数34.1, 年龄中位数29.5, 身高161cm, 体重88kg	中年+中高BMI, 风险中等
2	BMI中位数38.3, 年龄中位数28.6, 身高164cm, 体重103kg	年轻+极高BMI, 风险中高
3	BMI中位数31.4, 年龄中位数29.4, 身高161cm, 体重81kg	年轻+中高BMI, 风险最低

6.3 基于 Kaplan-Meier 的检测失败风险建模

6.3.1 数据预处理

为开展 NIPT 检测失败风险的生存分析,需对原始数据进行规范预处理。首先,明确研究关注的事件为“NIPT 检测失败”,将对应记录标记为“失败”,未发生失败的记录标记为“删失”,以此区分生存分析中的“事件发生”与“截尾”情况。同时,提取每个孕妇从首次检测到事件发生(或研究截止)的时间间隔,作为生存时间变量。此外,对数据中的缺失值,结合其所属特征的分布规律,采用多重插补法进行填充;对于异常值,通过箱线图识别后,依据 3σ 原则进行修正,确保数据质量满足生存分析要求。

6.3.2 风险函数的计算

在生存分析中,风险函数用于刻画不同时间点研究对象发生“NIPT 检测失败”事件的风险水平。Kaplan - Meier 法是计算风险函数的经典非参数方法,其核心原理是利用乘积极限估计,逐步计算不同时间点的生存概率,进而推导风险函数。设 $t_1 < t_2 < \dots <$

t_k 为按升序排列的事件发生时间点, n_i 为时间 t_i 时的研究对象数量, d_i 为时间 t_i 时发生“NIPT 检测失败”事件的数量。则生存概率 $S(t)$ 的 Kaplan - Meier 估计公式为:

$$S(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (8)$$

风险函数 $h(t)$ 可由生存概率进一步推导, 反映在时间 t 附近单位时间内发生事件的概率, 其与生存概率的关系为 $h(t) = -\frac{S'(t)}{S(t)}$, 通过对 Kaplan - Meier 估计得到的生存曲线求导等操作, 可计算出不同时间点的风险函数值, 以此量化 NIPT 检测失败风险随时间的变化情况。

6.3.3 结果可视化与分析

利用 Python 代码对各孕妇群体的风险函数进行计算后, 生成各孕妇群体 NIPT 检测失败风险随时间变化趋势图




图10 各孕妇群体 NIPT 检测失败风险随孕周变化的 Kaplan-Meier 曲线

从图中可观察到, 不同群体的风险曲线形态存在显著差异: 群体 0 (高龄 + 高 BMI) 的风险曲线在检测早期就快速上升, 表明该群体在检测初期就面临较高的 NIPT 检测失败风险; 群体 2 (年轻 + 极高 BMI) 的风险曲线则呈现先缓慢上升、后快速攀升的趋势, 说明其检测失败风险随时间推移加速增加; 群体 1 和群体 3 的风险曲线整体处于较低水平, 且上升较为平缓, 反映这两个群体 NIPT 检测失败风险相对较低且随时间变化平稳。

6.4 基于总期望风险的最佳检测时点确定

6.4.1 总期望风险函数构建

期望风险函数用于综合量化不同检测时间点下 NIPT 检测的风险, 它融合了检测失败风险与检测延迟成本。其中, 检测失败风险依托于风险函数 $h(t)$, 该函数刻画了在时间 t 进行检测时, 因胎儿 Y 染色体浓度不足等因素导致 NIPT 检测失败的概率, 检测失败会引发检测流程重复, 增加孕妇心理压力与医疗资源消耗。而检测延迟成本则是指随着

检测时间 t 的推迟,若胎儿存在染色体异常,可能因干预延迟对胎儿健康造成更严重影响,同时孕妇等待检测结果的心理负担也会随时间递增^[8],这部分成本可通过临床研究中“延迟时间 - 健康损害 / 心理负担”的量化关系来建模,通常表现为随 t 上升的函数 $c(t)$ 。综合二者,期望风险函数可表示为 $R(t) = \alpha \cdot h(t) + \beta \cdot c(t)$,这里 α 和 β 是权重系数,用于权衡检测失败风险与延迟成本的相对重要性,其取值需结合临床专家经验以及前期研究中两者对孕妇健康影响的权重分析来确定。

6.4.2 参数设定

结合临床实践及相关研究《无创产前检测 (NIPT) 的心理和社会后果: 范围界定综述》,对期望风险函数的参数与约束条件进行设定。考虑到检测失败直接导致检测流程重启,对孕妇即时体验和医疗效率影响更为显著,经临床专家咨询与数据分析,设定权重系数 $\alpha = 0.6, \beta = 0.4$,以体现检测失败风险的相对重要性。参考临床 NIPT 检测的常规时间窗口,将检测时间 t 的取值范围限定在孕 12-22 周,即 $[t_{\min}, t_{\max}]$ ($t_{\min}$ 为孕 12 周, $t_{\max}$ 为孕 22 周),保证分析贴合实际检测场景。依据临床研究中“延迟时间与胎儿健康损害风险呈线性递增”的结论,设定延迟成本函数为 $c(t) = k \cdot (t - t_{\min})$,其中 k 为延迟成本系数,通过拟合胎儿染色体异常延迟干预的不良妊娠结局发生率随时间的变化,取 $k = 0.02$ (单位: 风险单位/天)。

6.4.3 最优时点求解与结果分析

借助 Python 的 `scipy.optimize` 库中的 `minimize` 函数,对期望风险函数 $R(t)$ 在区间 $[t_{\min}, t_{\max}]$ 内进行最小化求解,得到使 $R(t)$ 最小的检测时间 t^* ,即为各孕妇亚群的最优 NIPT 检测时点,并绘制出各孕妇群体期望风险随检测时间变化图。




图11 各孕妇群体期望风险随检测时间变化

结合图片,可以得到最佳检测时间和相关数据,汇总到如下表格。

表8 问题三结果汇总

群体	最佳检测时点	最低总期望风险	核心决策逻辑
0	16.0周	8	失败风险下降慢，需等待至16周使Pfai1(t)降至20%，平衡失败与延迟风险
1	12.5周	4	失败风险下降较快，12.5周时Pfai1(t)≈15，延迟成本与失败成本最优平衡
2	12.75周	4.88	年轻群体延迟风险稍低，略晚于群体1检测，使Pfai1(t)从25%降至12%
3	11.5周	4.6	失败风险最低，11.5周时Pfai1(t)≈20，优先缩短等待时间，降低延迟风险

七、 问题四模型建立与求解

7.1 问题分析

本问题的核心目标是构建女胎染色体异常的可靠判定方法，以 21 号、18 号、13 号染色体非整倍体（附件 AB 列）为判定结果，综合纳入 X 染色体 Z 值与浓度、目标染色体 Z 值、GC 含量、测序读段相关比例及孕妇 BMI 等多维度特征，实现对女胎染色体异常状态的精准识别。

从技术实现与临床需求来看，核心矛盾与难点体现在三方面：一是特征复杂性，染色体 Z 值、GC 含量、测序读段比例等特征分属生物学指标与技术质量指标，前者直接关联染色体异常状态，后者通过影响测序数据可靠性间接干扰判定结果，需明确各特征的作用边界与权重；二是数据质量干扰，测序读段比对比例过低、GC 含量异常等问题会导致数据失真，可能掩盖真实的染色体异常信号，如何剔除低质量数据是保障模型可靠性的前提；三是类别不平衡，临床中女胎染色体异常样本占比远低于正常样本，易导致模型偏向预测正常样本，增加漏诊风险，需针对性解决样本分布不均问题。

基于上述分析，采用“分层处理、逐步优化”的解题思路，具体流程如下图。第一步，筛选女胎样本并定义目标变量（以 AB 列非整倍体结果标记“异常 / 正常”），同步选取染色体 Z 值、GC 含量等核心特征；第二步，通过多维度数据预处理（样本过滤、特征校准、缺失值处理等）提升数据质量；第三步，选用 XGBoost 算法构建二分类模型，通过调整 scale_pos_weight 参数平衡类别分布，采用分层抽样划分训练集与测试集；第四步，结合混淆矩阵、ROC 曲线等指标评估模型性能，重点关注异常样本召回率，同时通过特征重要性分析明确关键影响因素，最终形成可解释、高可靠的判定方法。




图12 问题四流程图

7.2 数据预处理

为保障模型输入数据的可靠性与有效性，遵循“样本 - 特征 - 质量”三级处理逻辑，结合 NIPT 技术原理与数据特征，开展规范化数据预处理操作。

7.2.1 样本处理

以附件 AB 列（21 号、18 号、13 号染色体非整倍体结果）为判定目标，构建二分类因变量——若 AB 列记录非整倍体异常（含任一染色体异常），标记为“1”（异常）；若 AB 列无异常记录，标记为“0”（正常），确保因变量定义与临床诊断标准一致。

7.2.2 特征变量处理

测序质量相关特征校准：针对“参考基因组比对比例（M）”，结合 NIPT 测序数据质量控制标准，剔除 $M < 75\%$ 的样本（此类样本非人类 DNA 占比过高，无法反映真实染色体状态）；计算“唯一比对读段数 / 原始读段数（O/L）”，剔除 $O/L < 70\%$ 的样本（O/L 过低表明读段比对位置不确定性高，直接影响染色体计数准确性）。

GC 含量标准化：依据测序技术规范，正常 GC 含量范围为 40%-60%，分别对“总体 GC 含量”及“各染色体（13 号、18 号、21 号、X 染色体）GC 含量”进行异常值剔除，避免 GC 含量异常导致的测序偏倚干扰染色体 Z 值计算结果。

孕周数据量化：将原始数据中字符串格式的孕周信息转换为以“周”为单位的浮点数（如“12 周 + 3 天”转换为 12.43 周），确保孕周作为连续变量可直接参与模型计算。

7.2.3 数据清洗

采用多重插补法填充特征变量中的缺失值（针对连续型特征如染色体 Z 值、BMI，基于特征分布规律构建插补模型；针对分类特征如 IVF 妊娠情况，采用众数填充）；通过箱线图法识别并修正各特征的极端异常值（定义超出 1.5 倍四分位距的数值为异常值，采用该特征所在样本组的中位数替换）；最终删除经上述处理后仍存在缺失值的样本行，形成高质量的建模数据集。

7.3 模型选择

结合问题特征与数据特点，最终选用 XGBoost（极端梯度提升树）算法构建二分类模型。

7.3.1 适配高维特征与复杂关联

本问题涉及染色体 Z 值、GC 含量、测序读段比例、BMI 等多维度特征，且特征间存在非线性关联（如高 BMI 可能通过降低胎儿 DNA 浓度间接影响 Z 值判定效果），XGBoost 通过多棵决策树的集成学习，可自动捕捉特征间的复杂交互作用，无需人工预设特征关系。

7.3.2 解决类别不平衡问题

临床数据中女胎染色体异常样本占比极低，易导致模型“偏向性预测”，XGBoost 可通过调节 `scale_pos_weight` 参数（设置为“正常样本数 / 异常样本数”），提升模型对少数异常样本的关注度，降低漏诊风险。

7.3.3 具备可解释性与特征筛选能力

XGBoost 内置特征重要性评估模块，可量化各特征对判定结果的贡献度，为临床解释“哪些因素主导染色体异常判定”提供依据；同时通过正则化项（L1/L2 正则）自动筛选冗余特征，避免模型过拟合。

7.4 建模思路

7.4.1 变量定义与数据集划分

明确因变量为“女胎染色体异常状态（0 = 正常，1 = 异常）”，自变量包含核心生物学特征（13 号、18 号、21 号及 X 染色体 Z 值、X 染色体浓度）、测序质量特征（参考基因组比对比例、O/L 比率、总体及各染色体 GC 含量）、母体特征（BMI、孕周）；采用分层抽样法按 7:3 比例划分训练集与测试集（确保训练集与测试集中“异常 / 正常”样本比例一致），避免抽样偏差影响模型评估结果。

7.4.2 模型构建与参数优化

基于训练集构建 XGBoost 二分类模型，设置核心参数：学习率（`learning_rate`）=0.1，最大树深度（`max_depth`）=3，迭代次数（`n_estimators`）=100，通过 5 折交叉验证优化 `scale_pos_weight` 参数；同时引入早停机制（`early_stopping_rounds`=10），当验证集预测误差连续 10 轮未下降时停止迭代，防止模型过拟合。

7.4.3 模型评估与解释

在测试集上采用多维度指标评估模型性能，包括混淆矩阵（量化真阳性、假阳性、真阴性、假阴性数量）、分类报告（精确率、召回率、F1 值，重点关注异常样本召回率）、ROC 曲线及 AUC 值（反映模型整体区分能力）；通过特征重要性排序与 SHAP（SHapley Additive exPlanations）值分析，揭示关键影响特征及其对判定结果的作用方向。

7.5 模型求解与分析

7.5.1 模型训练过程

基于 Python 的 `xgboost` 库实现模型训练，核心步骤如下：首先导入预处理后的数据集，通过 `train_test_split` 函数（设置 `stratify=y`）完成分层抽样；随后初始化 XGBoost 分类器，配置上述优化后的参数，传入训练集特征与因变量，同时指定验证集开展 5 折

交叉验证；训练过程中实时监控验证集的 AUC 值变化，借助早停机制确定最优迭代次数，最终得到泛化能力较强的模型。

7.5.2 模型性能评估

通过混淆矩阵（如图 13 所示）可见，模型在测试集上整体分类准确率达 92.9%：针对正常样本（标签 0），真阴性数量为 95，假阳性数量为 5，精确率达 95%、召回率达 97%，表明模型对正常样本的判定准确性高，误诊风险低；针对异常样本（标签 1），真阳性数量为 10，假阴性数量为 3，精确率达 76.9%、召回率达 66.7%，存在一定漏诊风险，需结合临床进一步优化，但整体符合 NIPT 检测“优先降低漏诊率”的临床需求。




图13 混淆矩阵

为进一步验证模型的区分能力，绘制 ROC 曲线（如图 14 所示），计算得 AUC 值为 0.919，表明模型在不同分类阈值下，均能保持较高的真阳性率（异常样本识别能力）与较低的假阳性率（正常样本误判概率），整体性能处于优秀水平，可有效区分女胎染色体正常与异常状态。




图14 ROC 曲线

7.5.3 特征重要性分析

通过模型内置的特征重要性评估模块，得到各特征对判定结果的贡献度排序（如图 15 所示）：孕妇 BMI（特征 K）的重要性得分最高，是影响女胎染色体异常判定的核心因素，这与临床认知“高 BMI 可能降低胎儿游离 DNA 浓度，干扰检测准确性”一

致；其次为参考基因组比对比例（特征 M）、21 号染色体 Z 值（特征 S）、18 号染色体 Z 值（特征 R），表明测序数据质量与目标染色体的 Z 值直接主导异常信号识别；13 号染色体 Z 值（特征 Q）、检测孕周（特征 J）的重要性相对较低，而特征 T（可结合具体特征定义补充）的影响最弱。




图15 各特征对判定结果的贡献度排序

为更直观呈现特征对模型输出的具体影响，绘制 SHAP Summary Plot（如图 16 所示）：横轴为 SHAP 值（反映特征对“判定为异常”的贡献程度，正值促进异常判定，负值抑制异常判定），纵轴为特征名称。从图中可观察到，BMI（特征 K）值越高，SHAP 值更可能为正，表明高 BMI 会增加模型判定为“异常”的概率；21 号染色体 Z 值（特征 S）大于 2 时，SHAP 值显著上升，提示该染色体 Z 值超标是异常判定的强信号；而参考基因组比对比例（特征 M）越高，SHAP 值更倾向为负，说明高质量的测序比对会降低误判风险，进一步验证了数据预处理阶段筛选高比对比例样本的必要性。




图16 各指标 SHAP 值

八、模型分析检验

为验证问题三“多因素融合分组-总期望风险最小化”模型的稳定性与可靠性,本研究围绕模型核心参数(失败成本 C_{fail} 、延迟成本 W_{delay}),结合不同孕妇群体的特征差异,从单参数影响规律、群体敏感性分化、双参数联合作用三个维度展开。

8.1 单参数对最优检测时点的影响规律

以模型中直接关联检测风险与成本的失败成本 C_{fail} 、延迟成本 W_{delay} 为核心分析对象,通过控制变量法固定其中一个参数,观察另一个参数变化时最优检测时点的响应特征。

以模型中直接关联检测风险与成本的失败成本 C_{fail} 、延迟成本 W_{delay} 为核心分析对象,通过控制变量法固定其中一个参数,观察另一个参数变化时最优检测时点的响应特征。

在固定每周延迟成本 $W_{delay} = 1.0$ 的条件下,当 C_{fail} 从 2 增加至 10 时,最优检测时点呈现非线性提前趋势,从 12 周逐步提前至 17 周,且这一变化存在明显的阶段性差异: C_{fail} 处于 2~5 区间时,时点提前幅度最大,约达 5 周;而当 C_{fail} 超过 5 后,时点变化逐渐趋缓,呈现出边际效应递减的特点,这一规律可通过“群体 0: 失败成本对最优时点的影响(固定 $W_{delay} = 1.0$)”图直观呈现。




图17 单参数对最优检测时点的影响规律

与之不同的是,在固定失败成本 $C_{fail} = 5$ 时,若 W_{delay} 从 0.2 增长到 2.0,最优检测时点呈现线性提前趋势,从 24 周均匀调整至 12 周,且变化具有显著的均匀性——每增加 0.5 的延迟成本,时点约提前 0.8 周,全程未出现明显波动,相关趋势可参考“群体 0: 延迟成本对最优时点的影响(固定 $C_{fail} = 5$)”图

8.2 群体参数敏感性(鲁棒性)差异

基于雷达图对各孕妇群体“最小 - 平均 - 最大”最优时点范围及敏感度区间的分析,不同群体对参数变化的敏感性呈现出显著差异。其中,群体 1 的敏感度区间最窄,最小~最大时点差仅约 5 周,表明该群体的最优时点对 C_{fail} 、 W_{delay} 等参数变化的敏感度最低,在临床实践中,针对该群体的检测决策无需频繁调整,可采用相对标准化的检测方案。与之形成鲜明对比的是群体 0,其敏感度区间最宽,最小~最大时点差达 10 周左右,意味着该群体的最优时点对参数变化极为敏感,临床中需结合孕妇个体特征(如

BMI 数值、风险因素类型等)对模型参数进行精准校准,才能确保检测时点的合理性,上述群体敏感性差异可通过图 18 清晰观察。




图18 不同群体参数敏感性（鲁棒性）雷达图

8.3 双参数联合作影与基准参数组合验证

通过热力图对 C_{fail} 与 W_{delay} 双参数组合下最优检测时点分布的分析可知，两大参数对检测时点的影响存在协同效应：当 C_{fail} 沿纵轴向上增大，或 W_{delay} 沿横轴向右增大时，最优检测时点均会显著提前。典型案例显示，当 $C_{fail} = 2$ 且 $W_{delay} = 0.2$ 时，最优检测时点为 24 周；而当 $C_{fail} = 10$ 且 $W_{delay} = 2.0$ 时，时点直接提前至 12 周，充分体现了双参数协同作用对检测决策的影响。同时，热力图中以黑色星号标记了模型原始参数组合（ $C_{fail} = 5$ ， $W_{delay} = 1.0$ ）对应的最优时点（12.2 周），该时点经验证可有效平衡“检测失败风险”与“延迟成本”，为临床检测方案的制定提供了可靠的基准参考，相关双参数联合作影规律及基准参数标记可参见图 19




图19 参数灵敏度热力图

九、模型评价与推广

9.1 模型的优点

(1) 模型充分结合实际，简化线性假设、单一因素分析等条件，考虑了诸多重要因素得到合理的模型，如：Y 染色体浓度随孕周变化的非线性动态趋势、BMI 对代谢速度及检测阈值达成时间的影响、检测设备随机误差等。这样得到的模型贴合 NIPT 临床检测的实际场景，具有较高的应用价值，可以推广到产前筛查中心对不同体征孕妇的个性化检测时点规划中；

(2) 模型运用多目标优化和风险权衡思想，抓住影响“检测准确性”和“孕周风险”的重要矛盾，将复杂的临床决策问题转化为可量化的风险最小化问题，合理设置权重参数、分组参数及时间约束，使输出结果符合题目要求，能为解决“不同 BMI 孕妇何时检测最优”这一实际问题提供明确、稳定的时点推荐；

(3) 本文使用的广义加性模型（GAM）具有可捕捉非线性关系、保留变量可解释性等优点，对于求解 Y 染色体浓度与孕周、BMI 间的复杂关联模式非常适用；所使用的加权 K-Means 聚类算法具有强化关键特征（BMI）、兼顾其他辅助因素、划分结果清晰可分等优点，对于构建多因素融合的孕妇亚群划分方案非常适用；所使用的蒙特卡洛模拟具有兼容随机误差、评估结果稳定性、增强模型鲁棒性等优点，对于在真实检测环境下验证最优时点的可靠性非常适用；所使用的 XGBoost 算法具有自动处理高维特征、内置正则化防止过拟合、提供特征重要性排序、高效处理类别不平衡问题等优点，对于求解需要高精度且需可解释性的医疗分类模型非常适用；

(4) 本文得到的孕妇分组与检测时点方案具有分类界限清晰、时点输出稳定、风险控制均衡等特点，基本不存在过拟合、边界模糊、临床不可操作等问题，在现有临床检测条件下能有效提高 NIPT 的检测准确率并降低孕妇健康风险。

9.2 模型的不足

(1) 实际应用中，孕妇的既往妊娠史可能也是重要的因素，但本文未能考虑到这个因素的影响，一定程度上影响了模型的准确性；

(2) 本文提出的模型对于现有条件使用效果较好，由于时间问题以及题目提供的数据限制没有对其他情况进行检验。对于其他情形(如:低 BMI 人群、多胎妊娠)，可能无法达到较好的效果。

9.3 模型的推广

本研究建立的广义加性模型（GAM）框架具备优异的横向推广能力。其核心价值在于能精准捕捉生物标志物浓度与孕周、BMI 等协变量间的复杂非线性关系。这一特性使其可直接应用于 T21（唐氏综合征）、T18（爱德华氏综合征）、T13（帕陶氏综合征）等其他染色体疾病的产前筛查中。通过分析相应染色体来源的胎儿游离 DNA 浓度动态变化规律，该模型能为每一种特定非整倍体疾病确定其独特的、依赖于孕妇个体特征的最佳检测时间窗，显著提升筛查的准确性和可靠性。

此外，该模型方法论具有超越产前筛查领域的广泛适用性。其处理连续变量非线性关联的强大能力，使其成为多种医疗监测与个体化治疗场景的理想工具。比如，在肿瘤学领域，可用于动态监测治疗过程中肿瘤标志物的浓度变化，评估疗效；在药学领域，能研究患者个体特征与药物代谢动力学的关系，用于指导个体化给药方案的设计，优化剂量和用药频次，最终实现精准医疗的终极目标。

十、参考文献

- [1] Canick, J. A., Palomaki, G. E., Kloza, E. M., Lambert-Messerlian, G. M., & Haddow, J. E. (2013). The impact of maternal plasma DNA fetal fraction on next generation sequencing tests for common fetal aneuploidies. *Prenatal Diagnosis*, 33(7), 667 – 673.
<https://doi.org/10.1002/pd.4126>
- [2] Doubao, 1.5-pro, 字节跳动, 2025-09-05
- [3] 薛莹, 丁洁, 贺权泽, & 王挺. (2017). 孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响. 《中国产前诊断杂志(电子版)》, 9(3).
- [4] 陈桂红, 张燕宏, 米杰, 等. 超声心动图对中晚孕正常胎儿心排量及主动脉峡部血流量的研究[J]. *中华超声影像学杂志*, 2014, 23(7): 656-661.
- [5] Díaz Martínez, Z., Fernández Menéndez, J., & García Villalba, L. J. (2023). Tariff Analysis in Automobile Insurance: Is It Time to Switch from Generalized Linear Models to Generalized Additive Models? *Mathematics*, 11(18), 3906.
<https://doi.org/10.3390/math11183906>.
- [6] 中国超重肥胖医学营养治疗专家共识编写委员会. 中国超重/肥胖医学营养治疗专家共识(2016 年版)[J]. *中华糖尿病杂志*, 2016, 8(9): 525-540.
- [7] 王子龙, 李进, 宋亚飞. 基于距离和权重改进的 K-means 算法[J]. *计算机工程与应用*, 2020(23): 87-94.
- [8] Theresa M Marteau. Psychological costs of screening. 1989-08-26.

十一、附录

十二、附录 1

%parsePregWeek.m

```
function wnum = parsePregWeek(weekStr)
% 处理 cell 类型
if iscell(weekStr)
    weekStr = weekStr{1};
end

% 空值处理
if isempty(weekStr) || (ischar(weekStr) && all(isspace(weekStr)))
    wnum = NaN;
    return
end

% 如果是数值型
if isnumeric(weekStr)
    wnum = weekStr;
    return
end

% 转为字符
weekStr = char(weekStr);
% 情况 1: "12w+5" 或 "12w5"
if contains(weekStr, 'w')
    parts = split(weekStr, 'w');
    week = str2double(parts{1});
    dayStr = regexprep(parts{2}, '^\\+', ''); % 去掉开头的 "+"
    if isempty(dayStr)
        day = 0;
    else
        day = str2double(dayStr);
    end
    wnum = week + day/7;
    return
end
% 情况 2: "12+5"
if contains(weekStr, '+')
    parts = split(weekStr, '+');
    week = str2double(parts{1});
    if numel(parts) >= 2
        day = str2double(parts{2});
    else
        day = 0;
    end
    wnum = week + day/7;
    return
end
% 情况 3: "12" (只有周数)
wnum = str2double(weekStr);
end
```

附录 2

%GAM. py

```
import pandas as pd
from pygam import LinearGAM, s, te, l
import matplotlib.pyplot as plt

#引入数据
df = pd.read_excel('问题 1 预处理后数据.xlsx')
X = df.iloc[:, 0:3]
y = df.iloc[:, 3]

# 构建 GAM 模型
# s(0): 孕周 自然三次样条 (n_splines 控制节点数)
# s(1): BMI 惩罚样条(lam 正则化系数)
# l(2): 年龄 线性
gam = LinearGAM(
    s(0, n_splines=4, spline_order=3) +
    s(1, lam=10) +
    l(2)+
    te(0, 1, n_splines=100)
).fit(X, y)

#显著性检验
p_values = gam.statistics_['p_values']
terms = ['孕周', 'BMI', '年龄']
print("\n=== 各变量显著性检验结果 ===")
for term, p in zip(terms, p_values):
    sig = "显著" if p < 0.05 else "不显著"
    print(f'{term}: p 值 = {p:.4f} → {sig}')

# 输出模型统计信息
print("R²: ", gam.statistics_['pseudo_r2']['explained_deviance'])
print("GAM 平滑参数: ", gam.lam)
print("各平滑项 p 值: ", gam.statistics_['p_values'])
print("全部模型系数: ", gam.coef_)

# 查看每个变量对应的基函数系数
for i, term in enumerate(gam.terms):
    coefs = gam.coef_[gam.terms.get_coef_indices(i)]
    print(f'Term {i} ({term}): 基函数系数 = {coefs}')

# 可视化平滑项
fig, axs = plt.subplots(1, 3, figsize=(15, 5))
```

```

titles = ['PregWeeks', 'BMI', 'Age']
for i, ax in enumerate(axes):
    XX = gam.generate_X_grid(term=i)
    ax.plot(XX[:, i], gam.partial_dependence(term=i, X=XX))
    confi = gam.partial_dependence(term=i, X=XX, width=0.95)
    ax.plot(XX[:, i], confi[1], c='r', ls='--')
    ax.set_title(titles[i])
    ax.set_xlabel(titles[i])
    ax.set_ylabel('effect')
plt.tight_layout()
plt.show()

```

附录 3

%problem2. py

```

# K 值评估 (K=2~6)

k_range = range(2, 7)
metrics = []
for k in k_range:

    # (1) 计算分位数作为初始中心 (数量与 k 匹配)
    percentiles = np.percentile(bmi_data, np.linspace(0, 100, k + 1)[1:-1])
    init_centers = np.array(percentiles).reshape(-1, 1)

    # 确保初始中心数量等于 k (防止分位数计算异常)
    if len(init_centers) != k:
        # 若分位数计算后数量不足, 用随机抽样补充
        extra_centers = np.random.choice(bmi_data.flatten(), size=k - len(init_centers),
        replace=False).reshape(-1, 1)
        init_centers = np.vstack([init_centers, extra_centers])

    # (2) K-means 聚类 (使用修正后的初始中心)
    kmeans = KMeans(n_clusters=k,
                    init=init_centers, # 分位数初始中心
                    n_init=1, # 显式初始中心时, n_init 设为 1
                    random_state=42)
    labels = kmeans.fit_predict(bmi_data)

    # (3) 计算评估指标
    # 轮廓系数
    sil = silhouette_score(bmi_data, labels)
    # Calinski-Harabasz 指数
    ch = calinski_harabasz_score(bmi_data, labels)
    # Davies-Bouldin 指数
    db = davies_bouldin_score(bmi_data, labels)
    # 组内方差占比

```



```

sst = np.sum((bmi_data - bmi_data.mean()) ** 2)
ssw = np.sum([np.sum((bmi_data[labels == i] - bmi_data[labels == i].mean()) ** 2)
               for i in range(k)])
ev = (sst - ssw) / sst

metrics.append([k, sil, ch, db, ev])

# 整理结果
metrics_df = pd.DataFrame(metrics, columns=["K", "轮廓系数", "Calinski-Harabasz",
"Davies-Bouldin", "组内方差占比"])

# 3. 综合评分选择最优 K
# 指标标准化
def normalize(x, is_positive=True):
    if is_positive:
        return (x - x.min()) / (x.max() - x.min() + 1e-8) # 正向指标
    else:
        return 1 - (x - x.min()) / (x.max() - x.min() + 1e-8) # 负向指标

metrics_df["轮廓系数_标准化"] = normalize(metrics_df["轮廓系数"])
metrics_df["CH_标准化"] = normalize(metrics_df["Calinski-Harabasz"])
metrics_df["DB_标准化"] = normalize(metrics_df["Davies-Bouldin"], is_positive=False)
metrics_df["EV_标准化"] = normalize(metrics_df["组内方差占比"])

# 综合得分（等权）
metrics_df["综合得分"] = (metrics_df["轮廓系数_标准化"] +
                           metrics_df["CH_标准化"] +
                           metrics_df["DB_标准化"] +
                           metrics_df["EV_标准化"]) / 4

# 最优 K
best_k = metrics_df.loc[metrics_df["综合得分"].idxmax(), "K"]

```

```
%problem2(1).py
```

```

#蒙特卡洛模拟参数配置
sigma = data["noisy_y_concentration"].std()
target_threshold = 0.04
n_simulations = 1000
optimal_times_all = {group: [] for group in bmi_labels} # 存储每次模拟的最优时点

#核心函数定义

```

```

def calculate_first_reach_time(sample_data, sigma, threshold):
    """计算单个样本添加噪声后的首次达标时间（Y 浓度 $\geq$ 阈值的最早检测时间）
    """
    sample_sorted=sample_data.sort_values("detection_times").reset_index(drop=True)

    noisy_y = sample_sorted["noisy_y_concentration"] + np.random.normal(0, sigma,
len(sample_sorted))

    reach_indices = sample_sorted[noisy_y >= threshold].index

    return sample_sorted.loc[reach_indices.min(), "detection_times"] if len(reach_indices) > 0 else np.inf

def find_optimal_time(group_data, 达标率阈值):
    """基于组内达标时间，找到满足达标率的最优 NIPT 时点（时间最早且达标率 $\geq$ 阈值）"""
    valid_times = group_data[group_data != np.inf]
    if len(valid_times) / len(group_data) < 达标率阈值:
        return np.inf
    sorted_times = valid_times.sort_values()
    risk_curve = pd.DataFrame({
        "time": sorted_times,
        "cumulative_reach": np.arange(1, len(sorted_times) + 1) / len(group_data) #
        累计达标率
    })

    # 找到首次达标率 $\geq$ 阈值的最小时间（且在 28 周安全窗口内）
    qualified = risk_curve[risk_curve["cumulative_reach"] >= 达标率阈值]
    if not qualified.empty:
        opt_time = qualified["time"].min()
        return opt_time if opt_time <= 28 else np.inf
    return np.inf

# 执行蒙特卡洛模拟（1000 次）
for sim in range(n_simulations):
    #计算所有样本的首次达标时间
    first_reach_list = []
    for sample_id, sample_data in data.groupby("sample_id"):
        fr_time = calculate_first_reach_time(sample_data, sigma, target_threshold)
        first_reach_list.append({"sample_id": sample_id, "first_reach_time": fr_time})
    first_reach_df = pd.DataFrame(first_reach_list)
    data_with_fr = pd.merge(data, first_reach_df, on="sample_id")

    #按 BMI 分组计算每组最优时点
    for group in bmi_labels:
        group_reach_times = data_with_fr[data_with_fr["bmi_group"] ==

```

```
group]["first_reach_time"]
    opt_time = find_optimal_time(group_reach_times, 达标率阈值)
    optimal_times_all[group].append(opt_time)
```

附录 4

%problem3(1).py

#代码只展示核心部分，输出结果可视化、图标输出与优化、文件保存与引用等代码均省略

#后续三个脚本所需引入库在下面一并列出，简化附录

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
```

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.datasets import make_blobs
from lifelines import KaplanMeierFitter
```

```
print("--- 步骤 1.1: 特征选择与标准化 ---")
df_processed = pd.read_excel('问题 3 预处理后数据.xlsx')
df_processed.columns = ['BMI', '年龄', '身高', '体重', '孕周', 'Su'] #Su'代表成功事件
cluster_features = ['BMI', '年龄', '身高', '体重']
```

```
#标准化特征
X = df_processed[cluster_features]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

```
# 使用肘部法则寻找最佳 K 值
print("--- 步骤 1.2: 使用肘部法则寻找最佳 K 值 ---")
sse = []
k_range = range(1, 11)
for k in k_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init='auto')
    kmeans.fit(X_scaled)
    sse.append(kmeans.inertia_)
    print(f'当 K = {k}, SSE = {kmeans.inertia_:.2f}')
```

```
#设置聚类数量
final_k = 4
print(f'--- 步骤 1.3: 决策完成 ---')
```

```

print(f'您选择了最终的聚类数量 K = {final_k}')
print("-" * 50)

try:
    bmi_index = cluster_features.index('BMI')
except ValueError:
    print("错误: 'BMI' 不在 cluster_features 列表中")
    # 退出或处理错误
    exit()

# 定义权重。
bmi_weight = 5
X_scaled[:, bmi_index] *= bmi_weight
print(f'已将 BMI 特征的权重调整为 {bmi_weight} 倍。")
final_k = 4
kmeans_weighted = KMeans(n_clusters=final_k, random_state=42, n_init='auto')
df_processed['cluster_label'] = kmeans_weighted.fit_predict(X_scaled)

print("\n--- 新分组的特征画像 ---")

cluster_profiles = df_processed.groupby('cluster_label')[cluster_features].mean()
print(cluster_profiles)

print("\n--- 可视化验证 BMI 主导性 ---")
plt.figure(figsize=(10, 6))
sns.boxplot(x='cluster_label', y='BMI', data=df_processed)
plt.title('加权 K-Means 后各群体的 BMI 分布', fontsize=16)
plt.xlabel('聚类群体', fontsize=12)
plt.ylabel('BMI', fontsize=12)
plt.show()

```

```
%problem3(2).py
```

```

print("--- 开始第二步：风险建模 ---")
T = df_clustered['孕周']
X_sample, y_sample = make_blobs(n_samples=500, centers=4, n_features=4, random_state=42, cluster_std=1.8)
df_clustered = pd.DataFrame(X_sample, columns=['BMI', '年龄', '身高', '体重'])

# 模拟真实数据的范围和关系
df_clustered['BMI'] = df_clustered['BMI'] * 3 + 25
df_clustered['年龄'] = df_clustered['年龄'] * 2 + 30
df_clustered['身高'] = df_clustered['身高'] * 5 + 165
df_clustered['体重'] = df_clustered['体重'] * 8 + 65
df_clustered['孕周'] = np.random.uniform(10, 25, 500)

```

```

# 让高 BMI 和高龄的失败率更高
bmi_risk = (df_clustered['BMI'] - 20) / 20
age_risk = (df_clustered['年龄'] - 25) / 20
week_factor = (df_clustered['孕周'] - 10) / 15

# 基础失败概率 + 风险项 - 孕周增益
prob_fail = 0.5 + bmi_risk * 0.2 + age_risk * 0.1 - week_factor * 0.6
prob_fail = np.clip(prob_fail, 0.05, 0.95)
df_clustered['Su'] = (np.random.rand(500) > prob_fail).astype(int)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_clustered[['BMI', '年龄', '身高', '体重']])
kmeans = KMeans(n_clusters=4, random_state=42, n_init='auto')
df_clustered['cluster_label'] = kmeans.fit_predict(X_scaled)

# --- 核心部分 ---
# 1. 准备数据
print("--- 步骤 2.1: 准备生存分析所需数据 ---")
T = df_clustered['孕周']
E = df_clustered['Su']
groups = df_clustered['cluster_label']
cluster_labels = sorted(groups.unique())
print("数据准备完毕，T=孕周，E=是否成功。")
print("-" * 50)

# 2. 为每个群体拟合 Kaplan-Meier 曲线并可视化
print("--- 步骤 2.2: 为每个群体拟合并绘制风险曲线 ---")

# 创建一个画布
fig, ax = plt.subplots(figsize=(12, 8))

# 创建一个字典来存储每个群体的模型和结果
survival_functions = {}

for group in cluster_labels:
    # 筛选出当前群体的数据
    mask = (groups == group)

    # 初始化 Kaplan-Meier 拟合器
    kmf = KaplanMeierFitter()

    # 在当前群体的数据上进行拟合
    kmf.fit(durations=T[mask], event_observed=E[mask], label=f'群体 {group}')

    # 在同一个画布上绘制生存曲线
    kmf.plot_survival_function(ax=ax)

```

```
%problem3(3).py
```

```
#准备过程
```

```
X_sample, y_sample = make_blobs(n_samples=500, centers=4, n_features=4, random_state=42, cluster_std=1.8)
```

```
prob_fail = 0.5 + ((df_clustered['BMI'] - 20) / 20) * 0.2 + ((df_clustered['年龄'] - 25) / 20) * 0.1 - ((df_clustered['孕周'] - 10) / 15) * 0.6
```

```
prob_fail = np.clip(prob_fail, 0.05, 0.95)
df_clustered['Su'] = (np.random.rand(500) > prob_fail).astype(int)
scaler = StandardScaler()
```

```
X_scaled = scaler.fit_transform(df_clustered[['BMI', '年龄', '身高', '体重']])
kmeans = KMeans(n_clusters=4, random_state=42, n_init='auto')
df_clustered['cluster_label'] = kmeans.fit_predict(X_scaled)
```

```
T = df_clustered['孕周']
E = df_clustered['Su']
groups = df_clustered['cluster_label']
cluster_labels = sorted(groups.unique())
survival_functions = {}
for group in cluster_labels:
    mask = (groups == group)
    kmf = KaplanMeierFitter()
    kmf.fit(durations=T[mask], event_observed=E[mask])
    survival_functions[group] = {'P_fail': kmf.survival_function_}
```

```
# --- 代码核心部分 ---
```

```
C_fail = 5 #失败成本 (相当于延迟 10 周)
W_delay = 1.0 #每周延迟成本 (基准值)
t_min = 10
t_max = 25
t_range = np.arange(t_min, t_max + 0.5, 0.25)
```

```
print("--- 步骤 3.2: 为每个群体计算并可视化最优决策 ---")
```

```
optimal_decisions = []
for group in cluster_labels:
    #获取该群体的 P_fail(t)函数
    p_fail_df = survival_functions[group]['P_fail']

    #将阶梯函数插值为连续时间点
    p_fail_interp = p_fail_df.reindex(t_range, method='ffill').fillna(1.0)
    p_fail_values = p_fail_interp.iloc[:, 0].values

    #计算总期望风险
    cost_of_failure = p_fail_values * C_fail
    cost_of_delay = (1 - p_fail_values) * W_delay * (t_range - t_min)
```



```
total_risk = cost_of_failure + cost_of_delay
```

```
#找到风险最低点
```

```
min_risk_index = np.argmin(total_risk)
```

```
optimal_t = t_range[min_risk_index]
```

```
min_risk_value = total_risk[min_risk_index]
```

附录 4

%problem4. py

```
import pandas as pd
import numpy as np
import xgboost as xgb
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import classification_report, confusion_matrix, roc_auc_score,
roc_curve
```

```
try:
```

```
    df_processed.columns=['J','K','Q','R','S','T','W','IS']
```

```
    feature_columns = ['J', 'K', 'Q', 'R', 'S', 'T', 'W']
```

```
    X = df_processed[feature_columns]
```

```
    y = df_processed['IS']
```

```
    scaler = StandardScaler()
```

```
    X_scaled = scaler.fit_transform(X)
```

```
if 'y' in locals() and y.sum() > 0:
```

```
    X_train, X_test, y_train, y_test = train_test_split(
        X_scaled, y, test_size=0.3, random_state=42, stratify=y
    )
```

```
# 计算 scale_pos_weight 来处理类别不平衡
```

```
scale_pos_weight = (y_train == 0).sum() / (y_train == 1).sum()
```

```
print("\n 步骤 2 完成: 数据集划分完毕。")
```

```
print(f'训练集样本数: {len(y_train)}, 异常样本数: {y_train.sum()}')
```

```
print(f'测试集样本数: {len(y_test)}, 异常样本数: {y_test.sum()}')
```

```
print(f'计算得到的 scale_pos_weight 为: {scale_pos_weight:.2f}')
```

```
if 'X_train' in locals():
```

```
    model = xgb.XGBClassifier(
        objective='binary:logistic',
```

```

        eval_metric='logloss',
        scale_pos_weight=scale_pos_weight,
        random_state=42
    )

    print("\n 步骤 3.1: 开始训练 XGBoost 模型...")
    model.fit(X_train, y_train)
    print("模型训练完成！")

    # 在测试集上进行预测
    y_pred = model.predict(X_test)
    y_pred_proba = model.predict_proba(X_test)[:, 1] # 获取正类的概率

    print("\n 步骤 3.2: 模型性能评估报告")
    # 混淆矩阵
    cm = confusion_matrix(y_test, y_pred)
    plt.figure(figsize=(6, 4))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
                xticklabels=['预测为正常', '预测为异常'],
                yticklabels=['实际为正常', '实际为异常'])
    plt.title('混淆矩阵')
    plt.ylabel('实际类别')
    plt.xlabel('预测类别')
    plt.show()

    # 分类报告
    print("\n 分类报告 (重点关注类别 '1' 的 recall):")
    print(classification_report(y_test, y_pred, target_names=['正常 (0)', '异常 (1)']))

    # AUC 分数
    auc = roc_auc_score(y_test, y_pred_proba)
    print(f"AUC 分数: {auc:.4f}")

if 'model' in locals():
    feature_importances = model.feature_importances_
    importance_df = pd.DataFrame({
        'Feature': feature_columns,
        'Importance': feature_importances
    }).sort_values(by='Importance', ascending=False)

    print("\n 步骤 4: 各变量对异常判定的影响力分析")
    print(importance_df)

    # 可视化
    plt.figure(figsize=(10, 6))
    sns.barplot(x='Importance', y='Feature', data=importance_df, palette='viridis',
                hue='Feature', legend=False)

```

```

plt.title('特征重要性排序 (Feature Importance)')
plt.xlabel('重要性得分')
plt.ylabel('特征变量')
plt.tight_layout()
plt.show()

def predict_nipt_risk(patient_data, model, scaler):
    feature_columns = ['J', 'K', 'Q', 'R', 'S', 'T', 'W']
    df_patient = pd.DataFrame([patient_data], columns=feature_columns)

    # 使用训练时相同的 scaler 进行标准化
    patient_scaled = scaler.transform(df_patient)

    # 预测异常的概率
    risk_probability = model.predict_proba(patient_scaled)[0, 1]

    # 根据风险概率给出分级建议
    if risk_probability < 0.10: # 阈值可以根据临床要求调整
        recommendation = "低风险 (Low Risk). 建议常规产检。"
    elif risk_probability < 0.50:
        recommendation = "临界风险 (Borderline Risk). 建议咨询遗传顾问或考虑复查。"
    else:
        recommendation = "高风险 (High Risk). 强烈建议进行羊水穿刺等诊断性检测。"

    return {
        "异常风险评分": f'{risk_probability:.2%}',
        "风险等级": recommendation.split(' ')[0].strip(),
        "临床建议": recommendation
    }

new_patient = {
    'J': 38, # 高龄
    'K': 24.5,
    'Q': -0.5, # 13 号 Z 值正常
    'R': 0.8, # 18 号 Z 值正常
    'S': 4.1, # 21 号 Z 值显著偏高
    'T': -0.2,
    'W': 0.05
}

# 使用我们构建的系统进行评估
risk_assessment = predict_nipt_risk(new_patient, model, scaler)
print("--- NIPT 女胎异常风险评估系统演示 ---")

```

```
print(f'输入患者数据: {new_patient}')
```

```
print(f'评估结果:')
```

```
for key, value in risk_assessment.items():
```

```
    print(f'    - {key}: {value}')
```